

דוח מסכם - Social Network Analysis of the Marvel Universe

מגישים: רונן מיליכוב 322883224, שחר וילק 214149759, אור סדוף 315578609

1. מבוא

יקום מארוול (Marvel Universe) מתאפיין ברשת עצומה של אלפי דמויות ועשרות שנים של היסטוריה עשירה, עלילות וסיפורים המשתלבים ומתפצלים זה בזה. בשל קנה המידה העצום והמורכבות של יקום זה, כמעט בלתי אפשרי לעקוב ידנית אחר המבנה האמיתי שלו ואופן זרימת המידע בתוכו. כדי להתמודד עם אתגר זה ולנתח את "הבלאגן של הגודל", פרויקט זה ממדל את יקום מארוול כרשת חברתית אחת גדולה. באמצעות ייצוג הנתונים כגרף לא מכוון (Undirected Graph) – שבו כל צומת מייצג דמות, וקשת נמתחת בין שתי דמויות אם הן הופיעו יחד באותה חוברת קומיקס – אנו מיישמים עקרונות מתורת הגרפים כדי לחשוף את המכניקה הנסתרת של היקום.

המוטיבציה המרכזית במחקר זה היא לעבור מקריאה פסיבית של קומיקס לניתוח אלגוריתמי-מתמטי, שיאפשר לנו לגלות מה באמת מחזיק את היקום הזה יחד. ספציפית, פרויקט זה נועד לענות על שלוש שאלות מחקר מרכזיות:

1. **חלוקה לקהילות (Community Detection):** האם אלגוריתם מתמטי מסוגל לנתח את מבנה הרשת ולזהות לבדו, בצורה עיוורת לחלוטין וללא כל ידע מוקדם, את הקבוצות והחבורות המוכרות של מארוול (כגון האוונג'רס או אקס-מן)?
2. **מרכזיות ותיווך (Centrality):** מי הם הגיבורים המהווים את ה"דבק" של היקום? מטרתנו אינה למצוא רק את הדמויות הפופולריות ביותר, אלא לזהות את המגשרים – אותן דמויות שמשמשות כגשר טופולוגי ומחברות בין עולמות וחבורות שבדרך כלל מנותקים זה מזה.
3. **חיזוי קשרים עתידיים (Link Prediction):** בהתבסס על צורת הגרף הנוכחית בלבד, האם ניתן לחזות מתמטית אילו דמויות, שמעולם לא הופיעו יחד באותה חוברת בעבר, צפויות לשתף פעולה בקרוסאוברים הבאים של היקום?

2. עבודה קשורה

בחלק זה נסקור את הספרות המחקרית והאלגוריתמית המרכזיים שעליהם מתבסס הניתוח הטופולוגי של רשת מארוול בפרויקט זה. הגישה שלנו נשענת על שלוש משפחות של אלגוריתמים מתורת הגרפים: מדדי מרכזיות, זיהוי קהילות וחיזוי קשרים.

2.1. זיהוי "מתווכים" ומרכזיות ברשת (Centrality Measures)

- **המאמר/המושג המרכזי:** Freeman, L. C. (1977). *A Set of Measures of Centrality Based on Betweenness*.
- **סיכום ורלוונטיות:** במאמר זה, פרימן הגדיר את מדד ה-Betweenness Centrality כאמצעי לזיהוי צמתים השולטים על זרימת המידע ברשת. המדד מחושב על פי התדירות שבה צומת נמצא על המסלולים הקצרים ביותר (Shortest Paths) בין זוגות צמתים אחרים בגרף.
- **רלוונטיות לפרויקט:** בעוד שמדד ה-Degree Centrality מסייע לנו למצוא את הגיבורים הפופולריים ביותר (ה-Hubs), אנו משתמשים ב-Betweenness Centrality כדי לזהות את ה"מתווכים" והגשרים של יקום מארוול. יישום זה מאפשר לנו לאתר דמויות (כגון ספיידרמן) אשר מחברות בין עולמות וקבוצות גיבורים שבדרך כלל מנותקים זה מזה, ובכך מחזיקות את הרשת יחדיו.

2.2. גילוי קהילות ומודולריות (Community Detection & Modularity)

- **המאמר/המושג המרכזי:** Blondel, V. D., et al. (2008). *Fast unfolding of communities in large networks* (Louvain Algorithm).
- **סיכום ורלוונטיות:** מאמר זה מציג את אלגוריתם Louvain – אלגוריתם חמדן ויעיל במיוחד לגילוי קהילות ברשתות ענק. האלגוריתם פועל על ידי אופטימיזציה מקומית ואיטרטיבית של מדד ה"מודולריות", מדד שפותח על ידי Newman המעריך את צפיפות הקשתות בתוך הקהילות לעומת צפיפותן ברשת אקראית.
- **רלוונטיות לפרויקט:** בפרויקט זה, אנו מיישמים את אלגוריתם Louvain כדי לחלק את אלפי דמויות מארוול לקהילות באופן עיוור לחלוטין, ללא ידע עלילתי מוקדם. הרלוונטיות המרכזית של המאמר היא ביכולת שלנו לאמת האם המבנה הטופולוגי שנוצר ממקסום המודולריות תואם ל"אמת בשטח" (Ground Truth) של המטא-דאטה, ולבחון האם מתמטיקה טהורה מסוגלת לשחזר קבוצות קומיקס מוכרות כמו האוונג'רס והאקס-מן.

2.3. חיזוי קשרים עתידיים (Link Prediction)

- **המאמר/המושג המרכזי:** Liben-Nowell, D., & Kleinberg, J. (2003). *The link-prediction problem for social networks*.
- **סיכום ורלוונטיות:** מחקר זה בוחן כיצד ניתן לחזות יצירת קשרים חדשים ברשתות חברתיות על בסיס מדידת קרבה טופולוגית בין צמתים. המאמר סוקר ומשווה מדדים היוריסטיים המבוססים על סביבת הצומת, כגון Common Neighbors (שכנים משותפים), Jaccard Coefficient, ומדד Adamic-Adar הנותן משקל גבוה יותר לשכנים משותפים בעלי דרגה נמוכה.

- **רלוונטיות לפרויקט:** החלק הניסויי של הפרויקט שלנו נשען ישירות על מתודולוגיה זו. אנו מסתירים 1% מקשתות הגרף הקיימות כדי לייצר סביבת ניסוי מבוקרת (Test Set). לאחר מכן, אנו מפעילים את שלוש ההיוריסטיקות הללו (CN, JC, AA) על הגרף החסר Gtrain כדי לבחון באמצעות מדדי סיווג (Accuracy, Precision, Recall, F1-Score) האם ניתן לחזות במדויק שיתופי פעולה עתידיים בין דמויות שעוד לא נפגשו.

3. הגישה והמודל האלגוריתמי

בחלק זה נתאר בפירוט את מסד הנתונים, את האופן שבו מידלנו את הבעיה, ואת השלבים האלגוריתמיים לניתוח הרשת, בדגש על מערך הניסוי המבוקר שבנינו לחיזוי קשרים – המהווה את התרומה המחקרית המרכזית של פרויקט זה.

3.1 מסד הנתונים ובניית הגרף

לצורך ביצוע המחקר, השתמשנו במסד הנתונים "The Marvel Universe Social Network" מתוך אתר Kaggle. מידלנו את הנתונים כגרף לא מכוון המיוצג כ- $G=(V,E)$ באמצעות ספריית NetworkX ב-Python.

- קבוצת הצמתים V מייצגת 6,426 דמויות קומיקס ייחודיות.
- קבוצת הקשתות E כוללת 167,219 קשרים, כאשר קשת נמתחת בין שני צמתים אם שתי הדמויות הופיעו יחד באותה חוברת קומיקס.

3.2 ניתוח מרכזיות (Centrality Analysis)

כדי לאתר את דמויות המפתח של היקום, השתמשנו בשני מדדים טופולוגיים משלימים:

1. **Degree Centrality:** חישוב דרגת הצומת נועד לאתר את ה-"Hubs" – הגיבורים הפופולריים והמקושרים ביותר ברשת (כגון קפטן אמריקה וספיידרמן).
2. **Betweenness Centrality:** מדד זה נועד לאתר את הגיבורים המשמשים כ"גשרים" בין קהילות שונות. מכיוון שחישוב מדויק של מדד זה עבור גרף בסדר גודל כזה דורש סיבוכיות זמן של $O(V^2E)$, ביצענו קירוב מתמטי על ידי דגימה אקראית של 500 צמתים ($k=500$) משיקולי יעילות חישובית.

3.3 חלוקה לקהילות ואימות (Community Detection)

מטרתנו בשלב זה הייתה לבדוק האם טופולוגיית הרשת לבדה משקפת את המבנה הנרטיבי של הקומיקס. הפעלנו את אלגוריתם **Louvain** לאיתור קהילות בגרף. האלגוריתם מחלק את הצמתים לקבוצות באופן שממקסם את ציון המודולריות (Q) – מדד המעריך את איכות החלוקה. כדי לאמת את התוצאות, ביצענו אימות מול "האמת בשטח": חילצנו את חמש הדמויות בעלות הדרגה הגבוהה

ביותר מתוך כל קהילה שזוהתה, והצלבת את התוצאה מול המטא-דאטה כדי לבחון האם נוצרו קבוצות עלילתיות אותנטיות (כמו האקס-מן או היקום של ספיידרמן).

3.4. התרומה המרכזית: מערך הניסוי לחיזוי קשרים (Link Prediction)

כדי לבחון האם ניתן לחזות שיתופי פעולה עתידיים בין גיבורים על סמך מבנה הרשת, בנינו מערך ניסוי סיווג מבוקר וקפדני:

1. בניית קבוצת הבדיקה (Test Set Split):

- **דגימות חיוביות (Positive Samples - תווית 1):** הסרנו מהגרף באקראי 1% מהקשתות הקיימות (1,672 קשתות) ושמרנו אותן בצד כיעדי חיזוי.
 - **דגימות שליליות (Negative Samples - תווית 0):** יצרנו מספר זהה (1,672) של זוגות צמתים אקראיים שמעולם לא הייתה ביניהם קשת בגרף המקורי.
2. **גרף האימון (Gtrain):** הגרף שנותר לאחר הסרת 1% מהקשתות החיוביות הוגדר כגרף האימון, ועליו התבצעו כלל החישובים העתידיים ללא זליגת מידע.
3. **יישום היריסטיקות החיזוי:** עבור כל זוג צמתים בקבוצת הבדיקה (חיוביים ושליליים כאחד), חישבנו את שלושת המדדים הבאים על בסיס טופולוגיית Gtrain:

- **Common Neighbors (CN):** ספירת מספר השכנים המשותפים בין שני הצמתים.
 - **Jaccard Coefficient (JC):** ספירת השכנים המשותפים מנורמלת בסך כל השכנים של שתי הדמויות.
 - **Adamic-Adar Index (AA):** מתן משקל גבוה יותר לשכנים משותפים שהם עצמם בעלי דרגה נמוכה (כלומר, קשר מיוחד יותר).
4. **הערכת ביצועים:** כדי להשוות בין המדדים, הגדרנו סף החלטה (Threshold) פשוט: אם ציון ההיריסטיקה גדול מ-0 (קרי, קיים לפחות שכן משותף אחד), המודל חוזה יצירת קשת (1). אם הציון הוא 0, המודל חוזה שאין קשת (0). הערכנו את איכות החיזוי של כל מדד באמצעות מטריקות סיווג קלאסיות: Accuracy, Precision, Recall, ו-F1-Score.

4. תוצאות וממצאים

בחלק זה נציג את תוצאות הניסויים שלנו עבור כל אחת משאלות המחקר. התמקדנו לא רק במדדי הביצועים היבשים, אלא בעיקר בפרשנות שלהם ובמה שהם מלמדים אותנו על המבנה החברתי של יקום מארוול ועל התנהגות האלגוריתמים.

4.1. מרכזיות, פופולריות ותיווך (Centrality)

כדי להעריך את חשיבות הדמויות, השווינו בין Degree Centrality (הבוחן מקושרות ישירה) לבין Betweenness Centrality (הבוחן תיווך במסלולים קצרים).

- **ממצאים:** בעוד שקפטן אמריקה מוביל במדד ה-Degree (1,908 קשרים), מדד ה-Betweenness הציב את ספיידרמן במקום הראשון (ציון 0.072), ואף העלה דמויות כמו וולברין (0.035) למקומות הגבוהים ביותר בגרף.
- **פרשנות והסקת מסקנות:** שיטת ההערכה הכפולה חושפת תובנה נרטיבית מעניינת: יש הבדל מהותי בין להיות הדמות הכי "פופולרית" (קפטן אמריקה, שנמצא בלב קבוצת האוונג'רס) לבין להיות ה"דבק" של היקום. ספיידרמן מנצח במדד ה-Betweenness מכיוון שעלילתית הוא חוצה גבולות – הוא פועל גם ברמת הרחוב (עם דרדוויל), גם ברמה הקוסמית וגם באוונג'רס. וולברין מופיע כגשר קריטי מכיוון שהוא נקודת ההשקה המרכזית בין עולם ה-X-Men המבודד יחסית, לשאר יקום מארוול. מתמטיקת הגרפים הצליחה לכמת במדויק תפקידים עלילתיים.

4.2. זיהוי קהילות עיוור (Community Detection)

כדי להעריך את החלוקה לקהילות של אלגוריתם Louvain, השתמשנו במדד מתמטי (Modularity) ובאימות איכותני מול "האמת בשטח" (מטא-דאטה של הקומיקס).

- **ממצאים:** האלגוריתם חילק את הרשת ל-26 קהילות עם ציון Modularity של $Q=0.4228$. בחינת מנהיגי הקהילות (לפי Degree) הראתה כי קהילה #2 מורכבת מוולברין, ביסט וסייקלופס; קהילה #3 מספיידרמן, דרדוויל וג'יי ג'ונה ג'יימסון; וקהילה #4 מדוקטור סטריינג', סילבר סרפר וד"ר דום.
- **פרשנות והסקת מסקנות:** ציון $Q > 0.3$ מעיד על מבנה קהילתי מובהק מאוד. שיטת ההערכה מול האמת בשטח מוכיחה בצורה מרשימה שהאלגוריתם, שראה רק צמתים וקשתות אנונימיות ללא שום ידע על העלילה, הצליח לשחזר במדויק קבוצות של מארוול: קהילת המוטאנטים, קהילת "גיבורי הרחוב של ניו-יורק", והקהילה הקוסמית. מכאן אנו לומדים שכותבי הקומיקס שומרים על עקביות רשתית גבוהה מאוד, וממעטים לערבב בין קהילות אלא באירועי קרוסאובר חריגים.

4.3. חיזוי קשרים עתידיים (Link Prediction)

הערכנו את יכולת חיזוי הקשרים על ידי בניית מודל סיווג בינארי שבחן שלוש היוריסטיקות (CN, JC, AA) על סט בדיקה מאוזן שהכיל 1% קשתות מוסתרות ודגימות שליליות (Negative Samples). סף ההחלטה הוגדר כציון גדול מ-0.

- **ממצאים:** באופן מעניין, כל שלוש ההיוריסטיקות הניבו תוצאות הערכה זהות לחלוטין: Accuracy של 82.18%, ו-F1-Score של 84.87%. מדד ה-Recall עמד על 99.9%, בעוד ה-Precision עמד על כ-73.7%.



- **פרשנות והסקת מסקנות:**

1. **התלכדות המדדים:** העובדה שכל המדדים הניבו את אותן התוצאות נובעת מבחירת

סף ההחלטה. מבחינה מתמטית, ברגע שלשני גיבורים יש לפחות שכן משותף אחד, הציון שלהם בכל שלושת המדדים יהיה גדול מ-0. לכן, הפונקציה קיבלה את אותן החלטות סיווג בדיוק (1 או 0) ללא קשר למשקלות הייחודיים של Adamic-Adar או Jaccard.

2. **Recall לעומת Precision:** ציון ה-Recall הכמעט מושלם מלמד אותנו חוק רשתי

חזק ביקום מארוול: כמעט אף פעם לא נוצר קשר חדש בין שתי דמויות שאין להן לפחות מכר משותף אחד. מנגד, ה-Precision הנמוך יותר (73.7%) מייצג "אזעקות שווא" (False Positives) – מקרים שבהם המודל חזה שיהיה קשר כי לדמויות יש חברים משותפים, אך הקשר טרם התממש בפועל. מבחינה אנליטית, שגיאות אלו אינן בהכרח "כישלון" של המודל, אלא כר פורה לתחזיות אמיתיות: זוגות הדמויות הללו הם המועמדים הטבעיים והסבירים ביותר להיפגש בחבורות הקרוסאובר העתידיות של מארוול.



5. מסקנות

ניתוח יקום מארוול באמצעות תורת הגרפים הוכיח כי עולמות תוכן בדיוניים ומורכבים אינם מתנהגים כאוסף אקראי של נתונים, אלא מציגים טופולוגיה רשתית מאורגנת, עקבית וניתנת לחיזוי.

ממצאי הפרויקט מדגימים כיצד אלגוריתמים מתמטיים מסוגלים לשחזר ידע נרטיבי ללא כל התערבות אנושית או הבנה סמנטית של הטקסט:

1. **מבנה רשתי מובחן:** אלגוריתם Louvain זיהה בהצלחה את ה"משפחות" של מארוול (כגון חברות האקס-מן או העולם הקוסמי), מה שמעיד על כך שהיקום בנוי מקהילות צפופות בעלות גבולות ברורים, המקושרות ביניהן בעיקר באירועי שיא.
2. **חשיבות המתווכים:** זיהינו כי קיים פער מהותי בין "פופולריות" לבין "תיווך". בעוד שקפטן אמריקה הוא הדמות המקושרת ביותר (מבחינת Degree), דמויות כגון ספיידרמן ווולברין התגלו כקריטיות יותר ליציבות הרשת ולזרימת המידע בין הקהילות השונות (Betweenness). בלעדיהם, יקום מארוול היה מתפצל לתתי-גרפים מנותקים.
3. **יכולת חיזוי:** הניסוי המבוקר לחיזוי קשרים (Link Prediction) הניב דיוק של למעלה מ-82%. תוצאה זו מאששת את ההשערה כי כותבי הקומיקס פועלים לפי תבניות רשתיות מובהקות – קשרים עתידיים כמעט תמיד ייווצרו בין דמויות החולקות "מעגלים חברתיים" משותפים.

לסיכום, רשתות חברתיות מהוות כלי אנליטי רב-עוצמה שלא רק שופך אור על מבנה הנתונים הקיימים, אלא גם מספק כלים מעשיים לחיזוי אסטרטגי של התפתחויות עתידיות בתוך הרשת.

6. תרומת חברי הצוות

- **רון מיליכוב:** תכנן והקמת מערך הניסוי המבוקר לחיזוי קשרים (Link Prediction). יישום מדדי ההערכה (CN, JC, AA) על סט הבדיקה, כתיבת הפונקציות להפקת מטריקות הסיווג, כתיבת הדו"ח המסכם וניסוח הפרשנות האנליטית לתוצאות.
- **שחר וילק:** אחריות על שלב חלוקת הקהילות (Community Detection). מימוש אלגוריתם Louvain ב-NetworkX, חישוב ובחינת מדד המודולריות (Q), וביצוע האימות האיכותני של הקהילות אל מול המטא דאטה של הקומיקס.
- **אור סדוף:** אחריות על הקמת התשתית ועיבוד הנתונים. משיכת מסד הנתונים מ-Kaggle, ניקוי ובניית הגרף הלא מכוון, ומימוש אלגוריתמי המרכזיות (Degree Centrality ו Betweenness Centrality) לאיתור מוקדי הכוח ונקודות התיווך ברשת.