

אלגוריתמים ברשתות - הצגת הפרויקט

ניתוח רשתות חברתיות של יקום מארוול

מוגש על ידי: רונן מיליכוב, שחר וילק ואור סדוף

הקדמה ומוטיבציה

- **העולם של מארוול:** זאת רשת עצומה של אלפי דמויות וסיפורים שכולם קשורים אחד לשני בדרכים שקשה לעקוב אחריהן. עשרות שנים של היסטוריה ואינסוף קווי עלילה שנפגשים ומתפצלים.
- **להסתכל על זה כגרף לא מכוון:** במקום סתם לקרוא קומיקס, אנחנו הופכים את הכל לרשת חברתית אחת גדולה. צמתים - דמויות, קשתות - 2 דמויות שהופיעו ביחד באותו הקומיקס ("יחודי")
- **למה זה מעניין בכלל?** אי אפשר באמת להבין כמות כזאת של מידע לבד. בעזרת תורת הגרפים אנחנו מגלים מה באמת מחזיק את היקום הזה ואיך המידע רץ שם
- **מה המטרה שלנו:** להשתמש באלגוריתמים כדי לראות מי הדמויות הכי משפיעות, למצוא קבוצות נסתרות ולנסות להבין לאן העלילה הולכת בלי לנחש

אז מה הבעיה ומה אנחנו מנסים לחקור?

- **הבלאגן של הגודל:** יקום מארוול גדל בצורה פסיכית כבר עשרות שנים. עם אלפי דמויות ומיליון קווי עלילה, כמעט בלתי אפשרי להבין מה המבנה האמיתי שלו ואיך הכל קשור אחד לשני
- **שאלה 1 - איך הקהילות מתפצלות? (Communities):** האם אלגוריתם מתמטי מסוגל לקחת את כל ערימת הנתונים הזו ולזהות לבד, בצורה עיוורת לחלוטין, את החבורות המוכרות (כמו האוונג'רס או אקס-מן), בלי שהוא שמע עליהן פעם אחת בחיים שלו?
- **שאלה 2 - מי ה"דבק" של היקום? (Centrality):** אנחנו לא מחפשים סתם מי הגיבור הכי פופולרי שיש לו הכי הרבה חבורות. אנחנו רוצים למצוא את המגשרים – הדמויות שמשמשות כגשר ומחברות בין עולמות שבדרך כלל לא קשורים אחד לשני.
- **שאלה 3 - מי החברים החדשים שייפגשו? (Link Prediction):** האם לפי צורת הגרף הנוכחית, אנחנו יכולים לחזות אילו דמויות שעוד לא הופיעו יחד באותה חוברת הולכות לשתף פעולה בקרוסאוברים ובסרטים הבאים?

על אילו נתונים אנחנו עובדים?

- **מסד הנתונים שלנו:** מסד הנתונים בו אנו משתמשים נמשך ישירות מהאתר של קאגל (שם הדאטה סט - The

(Marvel Universe Social Network

- **איך בנוי הגרף שלנו?** זהו גרף לא מכוון (Undirected Graph). הצמתים (Nodes) הם דמויות הקומיקס, וקשת

(Edge) נמתחת בין שתי דמויות אם הן הופיעו יחד באותה חוברת קומיקס.

המטא-דאטה

מהו המטא-דאטה?

הדאטה סט מכיל קובץ נלווה שממפה כל דמות לחוברות הקומיקס המדויקות שבהן היא הופיעה (למשל: וולברין הופיע בחוברת "Uncanny X-Men #134").

חילוץ הנתונים האמיתיים על הדמויות:

מתוך שמות החוברות, אנחנו יכולים לסמן בצד את השיוך הקבוצתי האמיתי של הגיבורים (למשל, מי שמופיע בחוברות X-Men שייך לחבורת המוטאנטים).

השימוש שלנו במטא-דאטה:

הנתון הזה ישמש לנו כקריטריון הערכה אובייקטיבי. נבדוק האם אלגוריתם הקהילות (שמסתכל רק על צמתים וקשתות אנונימיות) הצליח לקלוע ולשחזר את הקבוצות האמיתיות מהמטא-דאטה.

הממצאים הראשוניים שלנו

- **מה כבר עשינו עד עכשיו?** יצרנו גרף נקי שמכיל צמתים (הדמויות) והקשרים ביניהם (הופעות משותפות) וביצענו חקירת נתונים בסיסית; הפעלנו אלגוריתם מדד מרכזיות כדי לחשב דרגה של כל צומת, כלומר מספר השכנים (הדמויות) שיש לכל צומת (דמות) בגרף.
- **מרכזי הרשת (ה-Hubs): איירון מן** עם 1522 קשרים, **ספיידרמן** עם 1737 קשרים ו-**קפטן אמריקה** עם 1908 קשרים
- **המספרים היבשים (סטטיסטיקות ראשוניות):** ברשת שלנו יש 6,426 דמויות ייחודיות, וביניהן יש 167,219 קשרים של הופעות משותפות וייחודיות.

גישת הפתרון שלנו להמשך (מה נשאר לנו לעשות)

- **ניתוח הקהילות (Community Analysis):** כדי לחלק את היקום לקבוצות, אנחנו מתכננים להריץ אלגוריתמים כמו Louvain או Girvan-Newman, שיודעים למצוא "חבורות" סגורות בגרף לפי צפיפות הקשתות.
- **מציאת הגיבורים ה"מתווכים" (Centrality Measures):** נפעיל מדד מרכזיות שנקרא Betweenness Centrality כדי למצוא את הדמויות שיושבות על מסלולי הקישור הקצרים ביותר ומגשרות בין חבורות מנותקות.
- **חיזוי העתיד של מארוול (Link Prediction):** נשתמש במדדים מתמטיים כמו Common Neighbors (שכנים משותפים) ו-jaccard Coefficient כדי לחזות אילו גיבורים שעוד לא נפגשו מעולם, הולכים לשתף פעולה בקרוסאובר הבא.

איך נעריך את הביצועים?

- **איך נמדוד את איכות הקהילות? (מדד ביצועים 1):** אנחנו לא ננחש אם הקהילות שנוצרו הן טובות. נשתמש במדד מתמטי שנקרא מודולריות (Modularity), ובנוסף נשווה את החלוקה של האלגוריתם לקבוצות האמיתיות מהמטא-דאטה (נבדוק אם הוא הצליח לבודד את האוונג'רס).
- **איך נמדוד את חיזוי הקשרים? (מדד ביצועים 2):** נעשה ניסוי מבוקר – נעלים מהגרף 10% מהקשרים הקיימים באופן אקראי ונשמור אותן בצד, נריץ אלגוריתמי חיזוי על הגרף החסר, ונבדוק באילו אחוזי דיוק (Accuracy / Precision) הם מצליחים לחזות ולגלות מחדש את הקשרים שהסתרנו להם.